



PROPOSAL TUGAS BESAR ANALISIS BIG DATA Sains Data Institut Teknologi Sumatera 2026

Judul Tugas Besar

Prediksi Kualitas Air Menggunakan Random Forest Classifier Berbasis PySpark untuk Mendukung Ketersediaan Air Bersih

Identitas Mahasiswa

No	Nama Peran	NIM	Username Github
1	Muhammad Aqil Ramadhan	123450066	MuhammadAqil1
2	Monica Patricia Tanjung	123450073	monica25c
3	Rafi Diva Efangga	123450001	rafidivaefangga
4	Chevando Daffa Pramanda	122450095	chevandodp
5	Allya Nurul Islami Pasha	122450033	allyapasha

Tema Tugas Besar

Air Bersih dan Sanitasi

Ringkasan Proposal

Ringkasan proposal (maksimum 300 kata) berisi Urgensi, tujuan, metode, dan luaran yang dihasilkan/targetkan

Kualitas air merupakan isu global yang berdampak langsung pada kesehatan manusia dan keberlanjutan lingkungan. Di banyak wilayah dunia, termasuk negara berkembang, metode konvensional pengujian laboratorium masih menjadi andalan evaluasi kualitas air, namun metode ini memiliki keterbatasan: membutuhkan waktu lama, biaya tinggi, dan tidak praktis untuk pemantauan real-time. Proyek ini bertujuan membangun model prediksi kualitas air berbasis Random Forest Classifier menggunakan PySpark, yang mampu mengklasifikasikan potabilitas air secara otomatis berdasarkan 10 parameter fisikokimia: pH, kekerasan, total padatan terlarut, kloramin, sulfat, konduktivitas, karbon organik, trihalometan, kekeruhan, dan potabilitas. Dataset yang digunakan adalah Water Quality Dataset dari Kaggle (3.276 sampel, format CSV). Metode utama adalah Random Forest Classifier dari Spark MLlib dengan pembagian data 80% training dan 20% testing. Evaluasi model menggunakan metrik akurasi, F1-score, precision, dan recall dengan target ≥ 1.0 (100%), mengacu pada hasil paper utama (Alomani et al., 2022, IJACSA Vol. 13 No. 6). Luaran yang ditargetkan meliputi: pipeline big data berbasis PySpark untuk prediksi potabilitas air, laporan analisis korelasi antar fitur, serta visualisasi distribusi fitur dan matriks evaluasi model. Proyek ini relevan dalam mendukung SDG ke-6 (Air Bersih dan Sanitasi untuk Semua) dengan menyediakan solusi pemantauan kualitas air yang efisien, skalabel, dan berbasis data.

Kata kunci

Isian 5 kata kunci yang dipisahkan dengan tanda titik koma (;)

Kata Kunci : Random Forest; Kualitas Air; PySpark; Machine Learning; Potabilitas Air

Substansi Usulan

Petunjuk: Pengusul hanya diperkenankan mengisi di tempat yang telah disediakan (diberi warna) sesuai dengan petunjuk pengisian dan tidak diperkenankan untuk memodifikasi template menghapus setiap bagian.

A. RINGKASAN PAPER

Pilih satu paper yang paling relevan dengan proyek Anda dan tuliskan ringkasannya disini. Jangan melebihi 2 halaman untuk bagian ini.

Tabel 1. Rincian Paper yang diulas

Judul	Prediction of Quality of Water According to a Random Forest Classifier
Penulis	Shahd Maadi Alomani, Najd Ibrahim Alhawiti, A'aeshah Alhakamy
Jurnal	International Journal of Advanced Computer Science and Applications (IJACSA)
Tahun	2022
URL	https://www.ijacsa.thesai.org (Vol. 13, No. 6, 2022)

1. LATAR BELAKANG

Gambarkan konteks paper: apa motivasi dan masalah yang dikemukakan para penulis? Masalah apa yang ingin mereka selesaikan atau pengetahuan apa yang ingin mereka temukan?

Air minum merupakan kebutuhan dasar manusia yang kualitasnya kian terancam akibat polusi industri, perubahan iklim, dan eksploitasi berlebihan terhadap sumber air bawah tanah maupun permukaan. Metode konvensional untuk mengevaluasi kualitas air, yaitu melalui analisis laboratorium, terbukti memakan waktu, biaya besar, dan tidak praktis untuk diterapkan secara masif. Penulis termotivasi untuk mencari pendekatan alternatif yang lebih efisien dengan memanfaatkan machine learning dan big data. Masalah inti yang ingin diselesaikan adalah bagaimana memprediksi kelayakan minum (*potability*) air sungai secara otomatis berdasarkan parameter fisikokimia yang terukur, tanpa harus bergantung penuh pada pengujian laboratorium manual. Penelitian ini berusaha menjawab dua pertanyaan: faktor apa yang paling memengaruhi kelayakan air, dan apakah model Random Forest dapat memprediksinya secara akurat.

2. RINGKASAN KONTRIBUSI

Setiap paper memberikan sesuatu yang baru. Uraikan kontribusi utamanya - algoritma baru, hasil eksperimen, dataset baru, atau analisis baru

Kontribusi utama paper ini adalah pengembangan pipeline machine learning berbasis PySpark di atas kerangka kerja Apache Spark yang mengimplementasikan algoritma Random Forest Classifier untuk memprediksi kelayakan minum air. Kontribusi ini mencakup beberapa hal yang saling melengkapi. Pertama, penelitian ini mendemonstrasikan penggunaan Spark MLlib dalam skenario klasifikasi kualitas air skala besar, yang merupakan pendekatan big data nyata, bukan sekadar machine learning biasa. Kedua, digunakan sepuluh fitur sekaligus (pH, kekerasan, padatan terlarut, kloramin, sulfat, konduktivitas, karbon organik, trihalometan, kekeruhan, dan kelayakan minum) sebagai variabel prediktor yang komprehensif. Ketiga, penelitian ini menerapkan pipeline ML lengkap mulai dari eksplorasi data, penanganan nilai NULL dengan imputasi rata-rata, analisis korelasi menggunakan heatmap, hingga evaluasi model dengan metrik akurasi, presisi, recall, dan F1-score. Model

berhasil mencapai akurasi sempurna 1,0 pada semua metrik evaluasi, dan secara komparatif mengungguli model-model dari penelitian sebelumnya berdasarkan nilai RMSE.

3. KETERBATASAN DAN DISKUSI

Identifikasi keterbatasan metodologi atau klaim generalisasi paper ini secara kritis. Apakah keterbatasan tersebut mengubah cara Anda menilai temuan paper ini?

Paper ini memiliki beberapa keterbatasan yang perlu dikritisi. Akurasi sempurna (1,0) pada semua metrik sangat tidak lazim dan menimbulkan kecurigaan adanya *data leakage* atau *overfitting*, terlebih tanpa penjelasan eksplisit dari penulis. Dataset juga tidak didokumentasikan secara memadai sumber, jumlah baris, dan distribusi kelas tidak disebutkan sehingga eksperimen sulit direproduksi. Selain itu, absennya *cross-validation* melemahkan validitas hasil, dan tidak ada diskusi mengapa model bisa sangat akurat padahal analisis korelasi menunjukkan tidak ada fitur yang berkorelasi kuat dengan kelayakan minum. Secara keseluruhan, keterbatasan-keterbatasan ini mengharuskan kita bersikap kritis terhadap generalisasi temuan paper ke konteks data dunia nyata.

4. MENGAPA PAPER INI?

Dari sekian banyak paper, mengapa Anda memilih ini? Apa yang menarik dari topiknya? Setelah membacanya, apakah Anda mendapat apa yang diharapkan?

Paper ini dipilih karena memiliki kesesuaian yang sangat kuat dengan tema mata kuliah Analisis Big Data, khususnya dalam hal penggunaan Apache Spark/PySpark sebagai platform pemrosesan terdistribusi dan penerapan machine learning pipeline untuk klasifikasi data skala besar. Topiknya relevan secara sosial dan lingkungan karena menyentuh isu kualitas air yang juga menjadi tantangan nyata di Indonesia. Paper ini menyajikan contoh konkret penerapan Spark MLlib yang dapat dipelajari dan direplikasi. Setelah membacanya, paper ini memberikan gambaran alur kerja end-to-end dari data mentah hingga evaluasi model dalam ekosistem big data, meskipun terdapat kekurangan pada sisi transparansi metodologi. Hal tersebut justru membuka ruang bagi pengerjaan tugas besar untuk memperbaiki dan memperluas pendekatan yang digunakan dalam paper.

5. KONTEKS RISET YANG LEBIH LUAS

Hubungkan paper ini dengan tema-tema besar dalam Big Data: pemrosesan terdistribusi, manajemen kualitas data, skalabilitas, analitik real-time vs. batch, atau kesiapan data untuk machine learning. Apakah metode ini berpotensi diterapkan ke domain lain?

Paper ini bersinggungan langsung dengan beberapa tema besar dalam Big Data. Dari sisi pemrosesan terdistribusi, penggunaan PySpark menunjukkan bagaimana beban komputasi ML dapat didistribusikan untuk menangani data dalam skala besar yang tidak mungkin diproses secara sekuensial. Dari sisi manajemen kualitas data, paper ini mencontohkan penanganan nilai hilang (NULL) dan normalisasi data sebagai langkah krusial sebelum pelatihan model. Dari sudut pandang analitik batch vs. real-time, penelitian ini beroperasi dalam mode batch, namun para penulis sendiri menyebutkan potensi pengembangan ke arah pemrosesan stream data sensor secara real-time di masa depan. Dalam konteks kesiapan data untuk machine learning, analisis distribusi probabilitas dan matriks korelasi yang dilakukan mencerminkan praktik baik eksplorasi data (EDA) sebelum pemodelan. Metode ini sangat bisa diterapkan ke domain lain seperti pemantauan kualitas udara, deteksi anomali pada data sensor IoT industri, atau sistem peringatan dini bencana lingkungan, yang semuanya melibatkan data multivariabel kontinu dalam skala besar.

B. DESKRIPSI PROYEK

1. TUJUAN UTAMA

Rumuskan tujuan proyek Anda, idealnya sebagai pertanyaan ilmiah. Contoh: “Apakah arsitektur Medallion berbasis Spark dapat meningkatkan throughput pemrosesan data ekspor dibandingkan pipeline tradisional?” Jelaskan mengapa tujuan ini penting dan memungkinkan dicapai. Sebutkan tujuan sekunder (stretch goal) jika ada, dan hubungkan dengan paper yang Anda pilih.

Apakah model Random Forest Classifier berbasis PySpark dapat memprediksi potabilitas air sungai dengan akurasi $\geq 95\%$ menggunakan 10 parameter fisikokimia, sebagai alternatif yang lebih efisien dibandingkan pengujian laboratorium konvensional?

Tujuan ini penting karena kualitas air minum merupakan isu kesehatan publik yang mendesak WHO melaporkan lebih dari 2 miliar orang tidak memiliki akses air minum yang aman. Pemantauan berbasis machine learning dapat memberikan solusi yang lebih cepat, murah, dan skalabel. Tujuan ini dapat dicapai karena dataset Water Quality (Kaggle) tersedia secara publik, platform PySpark sudah matang untuk implementasi, dan paper rujukan utama (Alomani et al., 2022) telah membuktikan feasibilitas pendekatan ini.

Tujuan sekunder (stretch goals): (1) Mengidentifikasi fitur fisikokimia yang paling berpengaruh terhadap potabilitas air menggunakan analisis feature importance dari Random Forest; (2) Memvisualisasikan distribusi probabilitas setiap fitur dan heatmap korelasi untuk mendapatkan insight data secara eksploratif; (3) Membandingkan performa Random Forest dengan baseline model (Decision Tree, SVM) menggunakan metrik RMSE dan F1-score; (4) Mendiskusikan potensi penerapan sistem prediksi ini untuk mendukung pencapaian SDG ke-6 dalam konteks Indonesia, merujuk pada studi Junaedi (2022) dan Wadu et al. (2020).

2. STUDI KASUS / DOMAIN APLIKASI

Domain apa yang menjadi fokus proyek Anda? Berikan contoh konkret: apa input datanya dan apa output analitik yang diharapkan? Jika sudah dijelaskan dalam ringkasan paper, maka buat lebih detail disini.

Domain proyek adalah kualitas air sungai dan air permukaan. Proyek ini berfokus pada klasifikasi biner potabilitas air: apakah suatu sampel air layak diminum (potable=1) atau tidak (potable=0) berdasarkan 10 parameter fisikokimia yang dapat diukur menggunakan sensor lapangan maupun data historis.

Input data: File CSV dari Kaggle (water_potability.csv) berisi 3.276 sampel air dengan 10 fitur numerik: pH (keasaman air, rentang 6.52–6.83 untuk air layak minum), Hardness (kekerasan dari garam magnesium dan kalsium, mg/L), Solids (total padatan terlarut, TDS dalam ppm), Chloramines (konsentrasi kloramin disinfektan, max 4 mg/L), Sulfate (sulfat alami dalam air, 3–30 mg/L), Conductivity (konduktivitas listrik, max 400 $\mu\text{S}/\text{cm}$), Organic_carbon (karbon organik total, <2 mg/L untuk air minum), Trihalomethanes (THM dari proses klorinasi, <80 ppm), Turbidity (kekeruhan, <5 NTU sesuai WHO), dan Potability (label target: 0=tidak layak, 1=layak minum).

Output analitik yang diharapkan: (1) Label klasifikasi potabilitas untuk setiap sampel air; (2) Probabilitas potabilitas sebagai indikator kepercayaan model; (3) Laporan metrik evaluasi model (accuracy, F1-score, precision, recall); (4) Heatmap korelasi antar fitur; (5) Grafik distribusi probabilitas setiap fitur (density plot); (6) Perbandingan performa Random Forest vs. baseline model.

3. DATASET

Sebutkan dataset yang akan digunakan (sumber, ukuran, format). Jelaskan prapemrosesan yang direncanakan. Jika mengumpulkan data sendiri, jelaskan caranya dan estimasi waktu yang diperlukan.

Dataset yang digunakan adalah Water Quality Dataset yang tersedia secara publik di platform Kaggle (<https://www.kaggle.com/datasets/adityakadiwal/water-potability>). Dataset ini mencakup 3.276 sampel air dengan format CSV (± 525 KB), berisi 10 kolom fitur fisikokimia numerik dan 1 kolom label target (Potability: 0 atau 1).

Rencana prapemrosesan data: (1) Eksplorasi data awal: pemeriksaan tipe data, statistik deskriptif (mean, std, min, max), dan identifikasi nilai NULL. Fitur pH (491 nilai NULL), Sulfate (781 nilai NULL), dan Trihalomethanes (162 nilai NULL) akan ditangani dengan imputasi mean kolom. (2) Pembersihan data: penghapusan data duplikat dan konversi tipe data dari string ke float. (3) Analisis korelasi: menggunakan heatmap Seaborn untuk mengidentifikasi hubungan antar fitur dan menentukan apakah reduksi dimensi diperlukan. (4) Normalisasi fitur: standardisasi menggunakan StandardScaler dari Spark MLlib agar semua fitur berada pada skala yang sama untuk optimasi performa model. (5) Pembagian dataset: 80% data training (± 2.620 sampel) dan 20% data testing (± 656 sampel) secara acak menggunakan randomSplit() di PySpark.

Sumber: Kaggle, dataset tersedia secara bebas, tidak memerlukan proses pengumpulan data lapangan. Estimasi waktu preprocessing: $\pm 2-3$ hari kerja untuk implementasi dan validasi pipeline.

4. ARSITEKTUR DAN TEKNOLOGI

Jelaskan komponen teknis utama yang akan digunakan dan bagaimana mereka berinteraksi. Jika menggunakan Medallion Architecture, jelaskan setiap lapisannya. Tunjukkan mana yang diimplementasikan sendiri dan mana yang menggunakan konfigurasi yang sudah ada.

Arsitektur proyek mengadopsi pipeline machine learning berbasis PySpark dengan alur: Ingesti Data $\rightarrow$ Preprocessing $\rightarrow$ Feature Engineering $\rightarrow$ Model Training $\rightarrow$ Evaluasi $\rightarrow$ Visualisasi.

Komponen teknis utama: (1) Apache Spark & PySpark (v3.x): platform komputasi terdistribusi untuk memproses dataset CSV skala besar menggunakan DataFrame API. PySpark memungkinkan operasi paralel yang jauh lebih cepat dibandingkan pemrosesan sekuensial Pandas. (2) Spark MLlib – Random Forest Classifier: library machine learning terintegrasi Spark untuk membangun model klasifikasi ensemble berbasis pohon keputusan. (3) PySpark Pipeline API: mengatur alur preprocessing dan training secara modular dan reproducible menggunakan objek Pipeline() dari pyspark.ml. (4) Seaborn & Matplotlib: library visualisasi Python untuk menghasilkan heatmap korelasi, density plot distribusi fitur, dan confusion matrix. (5) Jupyter Notebook: environment pengembangan interaktif untuk eksplorasi data dan dokumentasi analisis. (6) Google Colab / Databricks Community Edition (opsional): platform cloud untuk menjalankan PySpark tanpa perlu setup cluster lokal.

Interaksi komponen: Data CSV dibaca oleh Spark menggunakan SparkSession, lalu melalui pipeline preprocessing (VectorAssembler, StandardScaler), kemudian dilatih oleh RandomForestClassifier, dan akhirnya dievaluasi menggunakan MulticlassClassificationEvaluator.

Komponen utama: PySpark & Apache Spark, Random Forest Classifier (Spark MLlib), Python dan Jupyter Notebook

Diimplementasikan sendiri: pipeline preprocessing, penanganan nilai NULL, konversi tipe data dan normalisasi, pembagian dataset (80% training / 20% testing), konfigurasi Random Forest (jumlah tree, max depth, fitur sampling), serta visualisasi dan analisis hasil model (heatmap korelasi, distribusi fitur, evaluasi akurasi dan F1-score).

Menggunakan konfigurasi yang tersedia : Random Forest dari Spark MLlib untuk klasifikasi potabilitas air, dan PySpark pipeline untuk mengatur alur preprocessing serta training model.

5. METODE PEMBANDING (BASELINE)

Metode apa yang digunakan sebagai pembandingan? Misalnya: pemrosesan sekuensial tanpa distribusi, pipeline sederhana satu lapisan, atau implementasi yang telah dipublikasikan. Jelaskan apakah diimplementasikan sendiri atau diambil dari sumber lain.

1. SMO-SVM (Sequential Minimal Optimization Support Vector Machine), digunakan di studi sebelumnya untuk prediksi kualitas air dengan dataset serupa. Evaluasi dilakukan menggunakan RMSE, R^2 , MAE, dan error relatif.
2. Decision Tree, KNN, SVR, MLR, Ridge Regression, GBRT, model-model ini digunakan sebagai perbandingan pada dataset yang sama untuk menilai keunggulan ensemble Random Forest.

Metode baseline ini diambil dari publikasi lain, tanpa modifikasi. Nilai evaluasi seperti RMSE atau F1-score dari model-model baseline ini menjadi tolok ukur untuk menilai keunggulan Random Forest yang diimplementasikan sendiri.

6. EVALUASI

Tentukan minimal satu metrik kuantitatif yang jelas. Contoh metrik yang umum digunakan: throughput (baris/detik), latensi end-to-end pipeline, akurasi prediksi (RMSE/MAE untuk regresi, silhouette score untuk clustering), atau rasio kompresi penyimpanan. Sebutkan nilai acuan (baseline score) yang ada di literatur atau yang Anda targetkan.

Rencana evaluasi proyek menggunakan metrik kuantitatif untuk menilai performa model Random Forest dalam memprediksi potabilitas air

Tabel 2. Metrik evaluasi yang direncanakan

Metrik	Acuan (Baseline)	Target
Akurasi klasifikasi (accuracy)	0.95 – 0.97 (model konvensional/SMO-SVM, Decision Tree, KNN)	≥ 1.0 (100%)
F1-score	0.94 – 0.96 (baseline)	≥ 1.0
Precision	0.94 – 0.96 (baseline)	≥ 1.0
Recal	0.94 – 0.96 (baseline)	≥ 1.0

- Akurasi (accuracy) menunjukkan seberapa sering model memprediksi potabilitas air dengan benar dibanding nilai aktual.
- F1-score merupakan kombinasi precision dan recall yang menyeimbangkan kemampuan model dalam mendeteksi air layak minum dan meminimalkan kesalahan prediksi.

- Target evaluasi ditetapkan pada 1.0 (100%), mengikuti hasil eksperimen dalam paper yang menggunakan Random Forest, di mana model mencapai akurasi, F1-score, precision, dan recall masing-masing 1.0 pada dataset yang digunakan

7. TANTANGAN ETIS DAN RISIKO SOSIAL

Tulis satu paragraf yang membahas: (A) minimal dua tantangan etis atau risiko sosial yang spesifik untuk proyek Anda - misalnya privasi data, potensi bias dalam model prediksi yang memengaruhi kebijakan, transparansi algoritma terhadap pemangku kepentingan, atau ketergantungan pada data yang tidak representatif - dan (B) strategi mitigasi yang spesifik dan praktis. Bagian ini dinilai berdasarkan kedalaman pemikiran.

Tantangan Etis :Salah satu tantangan etis utama adalah privasi dan representativitas data. Dataset kualitas air bisa berbeda antara sungai, wilayah hulu, dan musim tertentu, sehingga jika model dilatih hanya pada sebagian sampel, prediksi bisa bias dan tidak representatif untuk semua kondisi sungai, yang berpotensi memengaruhi kebijakan lingkungan atau keputusan pengelolaan sumber daya air. Risiko sosial lain adalah ketergantungan berlebihan pada prediksi otomatis tanpa verifikasi laboratorium, yang bisa menimbulkan risiko kesehatan jika model salah memprediksi potabilitas air.

Strategi :

- Menggunakan dataset yang beragam dari berbagai lokasi dan kondisi, serta pembagian data secara acak untuk mengurangi bias.
- Menyediakan indikator ketidakpastian prediksi sehingga pengguna dapat memverifikasi sampel kritis secara manual sebelum mengambil keputusan.
- Menekankan bahwa model sebagai alat bantu keputusan, bukan pengganti pengujian laboratorium, sehingga keputusan kebijakan tetap memperhatikan validasi lapangan dan protokol keamanan air.

REFERENSI

- [1] S. M. Alomani, N. I. Alhawiti, and A. Alhakamy, "Prediction of Quality of Water According to a Random Forest Classifier," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 13, no. 6, pp. 892–899, 2022. [Online]. Available: <https://www.ijacsa.thesai.org>
- [2] L. G. I. Fatristya, W. Saimah, I. Hadi, and E. Aryanti, "Peran Air Bersih dan Sanitasi dalam Meningkatkan Kualitas Hidup: Tinjauan Literatur terhadap Pencapaian Tujuan SDGs 2030," *GeoScienceEd*, vol. 6, no. 1, pp. 596–602, 2025. doi: <https://doi.org/10.29303/geoscienceed.v6i1.598>
- [3] M. Junaedi, "Sanitasi, Pengelolaan dan Akses Air Bersih Untuk Peningkatan Kesehatan di Indonesia," *Jurnal Tampiasih*, vol. 1, no. 1, pp. 6–10, 2022. E-ISSN: 2986-8742
- [4] L. B. Wadu, A. F. Gultom, and F. Pantus, "Penyediaan Air Bersih dan Sanitasi: Bentuk Keterlibatan Masyarakat dalam Pembangunan Berkelanjutan," *Jurnal Pendidikan Kewarganegaraan*, vol. 10, no. 2, pp. 80–87, 2020.
- [5] J. Xu, Z. Xu, J. Kuang, C. Lin, L. Xiao, X. Huang, and Y. Zhang, "An Alternative to Laboratory Testing: Random Forest-Based Water Quality Prediction Framework for Inland and Nearshore Water Bodies," *Water*, vol. 13, no. 22, p. 3262, 2021. doi: <https://doi.org/10.3390/w13223262>